

Modélisation statistique — Régression linéaire multiple

Exercice 1 (Régression linéaire multiple)

On considère le modèle de régression linéaire multiple

$$Y = X\beta + \epsilon,$$

avec $\beta \in \mathbb{R}^p$ inconnu et $\epsilon \sim \mathcal{N}(0, \Sigma)$. On suppose Σ connue et de rang plein (de rang n), mais pas nécessairement diagonale. On suppose de plus que $X \in \mathbb{R}^{n \times p}$ est de rang plein.

- 1) Considérons l'estimateur des moindres carrés ordinaire $\hat{\beta} = (X^\top X)^{-1} X^\top Y$. Calculer l'espérance et la matrice de variance-covariance de $\hat{\beta}$ sous les hypothèses données dans cet exercice.
- 2) Justifier l'existence d'une matrice Ω de taille $n \times n$ telle que $\Sigma = \Omega^\top \Omega$.
- 3) Montrer que $\Omega^{-1} X$ est de rang plein.
- 4) Soit $Y^* = \Omega^{-1} Y$, $X^* = \Omega^{-1} X$ et $\epsilon^* = \Omega^{-1} \epsilon$. Prouver que nous obtenons un nouveau modèle qui satisfait
 - (a) $\mathbb{E}[\epsilon_i^*] = 0$,
 - (b) $\text{Var}[\epsilon_i^*] = \sigma^2 > 0$ (erreurs de variance constante),
 - (c) $\text{Cov}(\epsilon_i^*, \epsilon_j^*) = 0$ pour tout $i \neq j$.
- 5) Déduisez un "meilleur" estimateur fonction de X, Y, Σ . Nous désignons par $\hat{\beta}_G$ cet estimateur.
- 6) Calculer $\mathbb{E}(\hat{\beta}_G)$ et $\text{Var}(\hat{\beta}_G)$.
- 7) Montrer que $\hat{\beta}_G$ est optimal parmi tous les estimateurs non biaisés T , c'est-à-dire que pour tout T

$$\text{Var}(T) - \text{Var}(\hat{\beta}_G)$$

est définie positive.

- 8) Conclure par une comparaison avec l'estimateur ordinaire des moindres carrés.

Exercice 2 (Régression ridge)

On considère le modèle linéaire Gaussien

$$Y = X\beta + \epsilon,$$

où $Y \in \mathbb{R}^n$ est le vecteur de réponses, $X \in \mathbb{R}^{n \times p}$ est la matrice de design (prédicteurs), $\beta \in \mathbb{R}^p$ est le vecteur (inconnu) de coefficients de régression, et $\epsilon \sim \mathcal{N}(0, \sigma^2 I_n)$. Soit $\lambda > 0$, on définit l'estimateur de la régression ridge par :

$$\hat{\beta}_\lambda^R = \underset{\beta \in \mathbb{R}^p}{\text{argmin}} \|Y - X\beta\|^2 + \lambda \|\beta\|^2.$$

- 1) Montrer que l'estimateur $\hat{\beta}_\lambda^R$ vérifie la relation

$$(X^\top X + \lambda I_p) \hat{\beta}_\lambda^R = X^\top Y.$$

- 2) Montrer que $X^\top X + \lambda I_p$ est inversible. En déduire une expression pour l'estimateur $\hat{\beta}_\lambda^R$.
- 3) Donner la limite de $\hat{\beta}_\lambda^R$ lorsque $\lambda \rightarrow 0$ et lorsque $\lambda \rightarrow \infty$.
- 4) Calculer le biais de l'estimateur ridge $\hat{\beta}_\lambda^R$.
- 5) Calculer la variance de l'estimateur ridge $\hat{\beta}_\lambda^R$.
- 6) Supposons que X est de rang plein (i.e. $X^\top X$ est de rang p). On souhaite comparer la variance de l'estimateur des moindres carrés classique $\hat{\beta}$ à l'estimateur ridge $\hat{\beta}_\lambda^R$.
- (a) Rappeler la formule donnant l'expression de l'estimateur des moindres carrés.
- (b) Définissons $P = \frac{1}{\lambda} X^\top X$. Montrer que

$$\text{Cov}(\beta) - \text{Cov}(\hat{\beta}_\lambda^R) = \sigma^2 \frac{1}{\lambda} (P + I_p)^{-1} [I_p + P^{-1} - P(P + I_p)^{-1}].$$

- (c) Montrer que la matrice au membre de droite de l'équation ci-dessus est semi-définie positive (i.e. $x^\top A x \geq 0$ pour tout x).
- (d) Quel est selon vous l'avantage principal de l'estimateur ridge ?