

Apprentissage supervisé

Exercice 1

On a observé les données suivantes : les features sont dans \mathbb{R}^2 et les labels sont dans {rouge, bleu}.

1. Donner les valeurs de l'erreur empirique associée à la perte 0/1 des classifieurs construits par
 - l'algorithme des 1-plus proche voisins (1-NN)
 - l'algorithme des 3-plus proche voisins (3-NN).
2. Où mettriez vous le premier “split” d'un arbre de décision ? (vous pouvez le dessiner sur la figure)
3. A partir de quelle profondeur a-t-on un arbre d'erreur empirique nulle ?



Exercice 2

On considère le problème de régression avec une régularisation ridge :

$$\operatorname{argmin}_{w \in \mathbb{R}^d, c \in \mathbb{R}} \left(\frac{1}{n} \sum_{i=1}^n \left(y_i - (x_i^\top w + c) \right)^2 + \frac{\lambda}{2} \|w\|_2^2 \right)$$

avec, pour $1 \leq i \leq n$, $x_i \in \mathbb{R}^d$ le vecteur de prédicteurs, $y_i \in \mathbb{R}$ la réponse, $w \in \mathbb{R}^d$ le vecteur de poids du modèle et $c \in \mathbb{R}$ l'intercept. On note de plus

$$f_i(w, c) = \left(y_i - (x_i^\top w + c) \right)^2 + \frac{\lambda}{2} \|w\|_2^2 \quad \text{and} \quad f(w, c) = \sum_{i=1}^n f_i(w, c).$$

1. On définit la matrice de design X comme

$$X = \begin{pmatrix} x_1^\top \\ \vdots \\ x_n^\top \end{pmatrix}.$$

Récrire la fonction f à minimiser en fonction du vecteur de paramètre $\theta = (w, c)^\top$, du vecteur $Y = (y_1, \dots, y_n)^\top$ et de la matrice $[\mathbf{1}|X]$ où $\mathbf{1}$ est le vecteur contenant n fois la valeur 1 et $[\cdot|\cdot]$ est la concaténation.

2. Calculer le gradient de $f(w, c)$ noté $\nabla f(w, c)$ par rapport au paramètre $\theta = (w, c)^\top$.
3. Dans la suite, on suppose qu'un **petit nombre d'observations** (x_i, y_i) sont des données aberrantes, dans le sens où y_i est loin de la valeur attendue. Au lieu d'avoir un intercept fixe $c \in \mathbb{R}$, on considère à présent un intercept par observation, c'est-à-dire $c_i \in \mathbb{R}$ pour $i = 1, \dots, n$, ce qui donne lieu au problème de minimisation suivant :

$$\operatorname{argmin}_{w \in \mathbb{R}^d, c \in \mathbb{R}^n} \left\{ \frac{1}{n} \sum_{i=1}^n f_i(w, c_i) + \gamma \|c\|_1 \right\}$$

où $f_i(w, c)$ a la même forme que précédemment, $\gamma > 0$ est un paramètre de régularisation supplémentaire, et où $\|c\|_1$ est la norme ℓ_1 ($\|c\|_1 = \sum_{i=1}^n |c_i|$). Ecrire la matrice de design associée à ce nouveau problème à partir de X et Id_n , la matrice identité de taille $n \times n$. Quelle est sa dimension ?

4. Expliquer en quelques mots pourquoi on utilise la pénalisation ℓ_1 pour le paramètre c , ainsi que l'effet du paramètre de régularisation $\gamma > 0$.
5. Ecrire l'algorithme de descente de gradient proximal pour résoudre le problème d'optimisation.

Exercice 3

1. Compléter le graphique du réseau de neurone pour la classification binaire avec une couche cachée à 1 neurone et dont la fonction d'activation en sortie de la couche cachée est g (vous pouvez vous aider des slides 5 à 7 du cours 4). On notera
 - b^H le vecteur de bias de la couche cachée
 - W^H le vecteur des poids de la couche cachée.
2. Préciser les dimensions de b^H , W^H , b^O , W^O .
3. Pour des valeurs fixées de b^H , W^H , b^O , W^O , donnez la forme mathématique de $\hat{y}(x)$.

On considère la perte logistique

$$\ell(y, \hat{y}(x)) = -y \log(\hat{y}(x)) - (1 - y) \log(1 - \hat{y}(x))$$

où y est le label observé et $x = (x_1, \dots, x^d)^\top$. On suppose, pour simplifier, que $b^H = b^O = 0$ et que g est la fonction sigmoïde. On veut calculer les gradients en W^H et W^O par back-propagation.

4. Calculer successivement les gradients

$$\nabla_{\hat{y}(x)} \ell(y, \hat{y}(x)), \nabla_{z^O} \hat{y}(x), \nabla_{W^O} z^O$$

en déduire l'expression de $\nabla_{W^O} \ell(y, \hat{y}(x))$.

5. Vérifier votre calcul en remarquant que

$$\ell(y, \hat{y}(x)) = -y \log(\sigma(W^O h)) - (1 - y) \log(1 - \sigma(W^O h)).$$

6. Si $W^{O,(k)}$ est la valeur de W^O à l'itération k , quelle sera sa valeur à l'itération $k + 1$ pour une descente gradient de pas η ?
7. Continuer avec

$$\nabla_h W^O, \nabla_{z^H} h, \nabla_{W^H} z^H$$

en déduire $\nabla_{W^H} \ell(y, \hat{y}(x))$.

1

x_1
 x_2
 \vdots
 x_d

