

Semaine 4 : Apprentissage non-supervisé et réduction de dimension

1 : Algèbre linéaire, SVD et matrices de covariances

Laurent Risser
Ingénieur de Recherche CNRS
Institut de Mathématiques de Toulouse / 3IA ANITI

lrisser@math.univ-toulouse.fr

0 : Introduction

La **factorisation de la matrice** est essentielle en *algèbre linéaire* dans et est ainsi utilisée dans de nombreux domaines dont l'*apprentissage automatique* :

- Cadre général → accélération de la résolution des problèmes de systèmes linéaires (il n'est pas toujours optimal d'inverser explicitement une matrice ou de calculer un déterminant).
- Apprentissage statistique → *identification de structures* au sein de données ou *réduction de dimension* des observations.

Différentes méthodes de factorisation de matrice existent :

- Racine carrée Cholesky d'une matrice
- Factorisation LU ou QR
- Décomposition de valeurs singulières (SVD)

Nous allons nous intéresser à la **SVD**, qui est la plus utile en apprentissage automatique.

$$\begin{bmatrix} \bullet & \bullet & \bullet & \bullet \\ \bullet & \bullet & \bullet & \bullet \end{bmatrix} = \begin{bmatrix} \bullet & \textcolor{magenta}{\bullet} & \bullet \\ \bullet & \bullet & \bullet \end{bmatrix} \begin{bmatrix} \bullet & & & \\ & \bullet & & \\ & & \bullet & \\ & & & \bullet \\ & & & & \bullet \end{bmatrix} \begin{bmatrix} \bullet & \bullet & \bullet & \bullet & \bullet \\ \bullet & \bullet & \bullet & \bullet & \bullet \\ \bullet & \bullet & \bullet & \bullet & \bullet \\ \bullet & \bullet & \bullet & \bullet & \bullet \\ \bullet & \bullet & \bullet & \bullet & \bullet \end{bmatrix}$$

M U D V^T

$n \times m$ $n \times k$ $k \times k$,
 $K = \text{rank } M$

Image : <https://www.math3ma.com/blog/understanding-entanglement-with-svd>

1 : Rappels d'algèbre linéaire - Espaces vectoriels

Partie inspirée de :

- Jean Fresnel : *Algèbre des matrices*. 2013 ([lien](#))
- Lloyd N Trefethen and David Bau III : Numerical linear algebra, volume 50. Siam 1997 ([lien](#))
- Cours de Samuel Bernard (CNRS)

Définition 1. Soit K un corps commutatif (\mathbb{R} ou \mathbb{C}). Un ensemble E muni d'une somme $+$ (application de $E \times E \rightarrow E$ commutative et associative avec élément 0 neutre et élément inverse) et d'une multiplication \cdot par un scalaire appartenant à K (application de $K \times E \rightarrow E$) est un **espace vectoriel** sur K , $(E, K, +, \cdot)$, s'il possède les propriétés suivantes:

Pour tout $\mu, \lambda \in K$ et $x, y \in E$,

$$\lambda \cdot (x + y) = \lambda \cdot x + \lambda \cdot y, \tag{1}$$

$$(\lambda + \mu) \cdot x = \lambda \cdot x + \mu \cdot x, \tag{2}$$

$$1 \cdot x = x, \tag{3}$$

$$\lambda \cdot (\mu \cdot x) = (\lambda\mu) \cdot x. \tag{4}$$

Définition 2. Soit E un espace vectoriel sur K . Une partie F non-vide de E est appelée **sous-espace vectoriel** de E , si pour tout $x, y \in F$ on a $x - y \in F$ et si pour tout $\lambda \in K$ et $x \in F$, on a $\lambda \cdot x \in F$. On utilise l'abréviation s.e.v. pour un sous-espace vectoriel.

Définition 3. Soit E et F deux e.v. sur K . Une application $f : E \rightarrow F$ est appelée **application linéaire** si

$$f(x + y) = f(x) + f(y) \quad \text{pour tout } x, y \in E \quad (5)$$

$$f(\lambda x) = \lambda f(x) \quad \text{pour tout } x \in E, \lambda \in K \quad (6)$$

Un **isomorphisme** est une application linéaire bijective. L'inverse d'un isomorphisme est aussi une application linéaire. Un **endomorphisme** de l'e.v. E est une application linéaire de E dans E . Un **automorphisme** est un endomorphisme bijectif.

Exemple : Matrice de rotation 2D

Définition 5. Soit E un e.v. sur K , on appelle **famille de E indexée par un ensemble I** une application de I dans E . Cette application associe $i \rightarrow x_i$. On note cette famille sous la forme $(x_i)_{i \in I}$. La notion de famille généralise celle d'une suite, où l'index n'est pas nécessairement entier.

Une famille $(x_i)_{i \in I}$ est **libre** si pour toute famille $(\lambda_i)_{i \in I}$, $\lambda_i \in K$ à support fini (c.-à-d. $\lambda_i \neq 0$ pour un nombre fini de valeurs $i \in I$), l'égalité

$$0 = \sum_{i \in I} \lambda_i x_i \tag{10}$$

implique $\lambda_i = 0$ pour tout $i \in I$.

Une famille $(x_i)_{i \in I}$ est **génératrice** si pour tout élément $x \in E$, il existe une famille $(\lambda_i)_{i \in I}$, $\lambda_i \in K$ à support fini telle que

$$x = \sum_{i \in I} \lambda_i x_i. \tag{11}$$

Une famille $(x_i)_{i \in I}$ de E est une **base** de E si elle est libre et génératrice. Ça veut dire que pour tout $x \in E$, il existe une famille *unique* $(\lambda_i)_{i \in I}$, $\lambda_i \in K$ à support fini telle que $x = \sum_{i \in I} \lambda_i x_i$. L'élément λ_i est la **coordonnée de x dans la base $(x_i)_{i \in I}$** .

Proposition 1.3. Soit E un e.v. de type fini, c.-à-d. que E admet une famille génératrice finie.
Alors

- i) E admet une base \mathcal{B} indexée sur un ensemble fini. Le cardinal (nombre d'éléments) de cet ensemble est noté $\text{card } \mathcal{B}$.
- ii) Soit \mathcal{B}' une base de E , alors \mathcal{B}' est une famille indexée sur un ensemble fini et $\text{card } \mathcal{B}' = \text{card } \mathcal{B}$.

Le $\text{card } \mathcal{B}$ s'appelle dimension de E sur K et se note $\dim_K E$. $\dim_K E = 0$ si $E = \{0\}$.

Définition 6. Soit E, F deux e.v. sur K de dimensions $n \geq 1, p \geq 1$, $(e_i)_n, (f_j)_p$ des bases de E et F , et $f : E \rightarrow F$ une application linéaire telle que

$$f(e_i) = \sum_{j=1}^p a_{ji} f_j. \quad (13)$$

Alors la **matrice de f dans les bases** $(e_i)_n$ et $(f_j)_p$, notée $\text{Mat}(f, (e_i)_n, (f_j)_p)$ est la famille $(a_{ji})_{(j,i) \in [1,p] \times [1,n]}$.

$$\text{Mat}(f, (e_i)_n, (f_j)_p) = \begin{pmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} \\ \vdots \\ a_{p1} & a_{p2} & \dots & a_{pn} \end{pmatrix} \quad (14)$$

Cette matrice est une **matrice à n colonne et à p lignes** et prend ses **entrées** $a_{ji} \in K$.

Définition 7. On définit le **produit matriciel** entre deux matrices $A \in M_{p,n}(K)$ et $B \in M_{n,\ell}(K)$ comme la matrice $C \in M_{p,\ell}(K)$ avec

$$c_{jk} = \sum_{i=1}^n a_{ji} b_{ik}. \quad (16)$$

On note le produit matriciel de A et B par AB .

Définition 8. Soit $A \in M_{p,n}(K)$ une matrice $p \times n$. On appelle **transposée** de A la matrice $[b_{ij}]_{ij} \in M_{n,p}(K)$ définie par $b_{ij} = a_{ji}$, et est notée ${}^t A$ ou \bar{A} .

On a ${}^t(A + B) = {}^t A + {}^t B$, ${}^t(\lambda A) = \lambda {}^t A$, ${}^t(AC) = {}^t C {}^t A$, et ${}^t({}^t A) = A$. On dit qu'une matrice carrée $A \in M_n K$ est **symétrique** si ${}^t A = A$.

Définition 9. Déterminant d'une matrice carrée. Soit $A = [a_{ij}]_{ij} \in M_n(K)$ une matrice $n \times n$. On appelle **déterminant de A** , noté $\det A$ le scalaire défini par

$$\det A = \sum_{\sigma \in \text{perm}(n)} \text{sgn}(\sigma) a_{\sigma(1)1} a_{\sigma(2)2} \dots a_{\sigma(n)n}. \quad (17)$$

On note aussi

$$\det A = \begin{vmatrix} a_{11} & \dots & a_{1n} \\ \vdots & & \vdots \\ a_{n1} & \dots & a_{nn} \end{vmatrix}. \quad (18)$$

La **signature** d'une permutation $\text{sgn}(\sigma)$ vaut 1 si la permutation σ est paire et -1 si la permutation est impaire. Une permutation est **paire** (respectivement **impaire**) si elle est le produit d'un nombre pair (impair) de transpositions (permutation de deux éléments entre eux).

Exemple : $\text{perm}(2) = \{ (1,2), (2,1) \}$. Retrouvez alors le déterminant d'une matrice 2×2 ?

1 : Rappels d'algèbre linéaire - Déterminant

Le déterminant possède les propriétés suivantes:

1. $\det I = 1.$
2. $\det A = \det {}^t A.$
3. $\det[C_1 \dots \sum \lambda_i C_j \dots C_n] = \lambda_i \det[C_1 \dots C - n] = \lambda_i \det C,$ où C_i sont les colonnes de $C.$
- 4.

$$\det \begin{bmatrix} L_i \\ \sum \lambda_i L_j \\ L_n \end{bmatrix} = \lambda_i \begin{bmatrix} L_i \\ \vdots \\ L_n \end{bmatrix}. \quad (19)$$

5. $\det[C_{\sigma(1)} \dots C_{\sigma(n)}] = \text{sgn}(\sigma) \det C.$
6. idem pour les lignes.
7. Si une ligne (colonnes) est une combinaison linéaire d'autres lignes (colonnes), alors $\det = 0.$
8. Soit A avec $a_{i1} = 0$ pour $i \geq 2$ et $B = [b_{ij}]$ avec $b_{ij} = a_{i+1,j+1}.$ Alors $\det A = a_{11} \det B.$
9. $\det AB = \det BA = \det A \det B.$
10. A est inversible si et seulement si $\det A \neq 0.$

2 : Projection sur une base


Projection orthogonale sur une droite

Soit x un vecteur non nul de E et soit D la droite vectorielle engendrée par x , i.e. $D = \{\lambda x \mid \lambda \in \mathbb{R}\}$. Soit $y \in E$. On veut projeter le vecteur y orthogonalement sur la droite D . On note $\Pi_D(y)$ la projection orthogonale de y sur D . Elle est caractérisée par les deux propriétés suivantes :

- (i) $\Pi_D(y) \in D$, i.e. $\Pi_D(y)$ est colinéaire à x
- (ii) $y - \Pi_D(y)$ est orthogonal à x .

On en déduit la solution :

$$\Pi_D(y) = \frac{\langle x, y \rangle}{\|x\|^2} x .$$



2 : Projection sur une base

Projection orthogonale sur un sous-espace vectoriel

Soit A une matrice de taille $m \times n$. Soit A_1, \dots, A_n ses colonnes. Ce sont des vecteurs de \mathbb{R}^m . Par exemple, si

$$A = \begin{pmatrix} 1 & 2 \\ 3 & -4 \\ 2 & 0 \end{pmatrix},$$

ses colonnes sont

$$A_1 = \begin{pmatrix} 1 \\ 3 \\ 2 \end{pmatrix}, \quad A_2 = \begin{pmatrix} 2 \\ -4 \\ 0 \end{pmatrix}$$

On cherche à déterminer la projection orthogonale d'un vecteur y sur le sous espace vectoriel de \mathbb{R}^m engendré par A_1, \dots, A_n . Cette projection, notée Π_A est caractérisée par les propriétés

- (i) $\Pi_A(y)$ est une combinaison linéaire des colonnes de A ;
- (ii) $y - \Pi_A(y)$ est orthogonal aux colonnes de A .


2 : Projection sur une base

Projection orthogonale sur une base




Théorème Soit A une matrice de taille $m \times n$ et soit $y \in \mathbb{R}^m$. Si la matrice ${}^t A A$ est inversible, alors la projection orthogonale de y sur le sous-espace de \mathbb{R}^m engendré par les colonnes de A est

$$A ({}^t A A)^{-1} {}^t A y .$$

2 : Projection sur une base - Illustrations





Projections sur une série de Fourier




2 : Projection sur une base - Illustrations

Base de Fourier : $\varphi_j(s) = \cos(\pi c_j s)$, où c_j contrôle les propriétés de chaque projection



2 : Projection sur une base - Illustrations

Base d'ondelettes: projections dépendant de l'échelle et de la localisation



2 : Projection sur une base - Illustrations

Transformations rigides d'images : projection des coordonnées des pixels à l'aide d'une matrice modélisant une rotation et une translation




Image A

Image B

**Image A with
overlaid Image B**

**Image A with
overlaid Image B
after translation-
rotation**

3 : Décomposition en valeurs propres

Partie inspirée de : *Algèbre des matrices*. (Jean Fresnel, 2013, [lien](#)) et Cours de Samuel Bernard (CNRS)

Définition Une **décomposition en valeurs propres** d'une matrice carrée A est une factorisation

$$A = XDX^{-1},$$

avec X une matrice inversible et D une matrice **diagonale** ($D = [d_{ij}]$ avec $d_{ij} = 0$ si $i \neq j$).

Par définition de la multiplication de deux matrices, si x_i est la i ème colonne de X et λ_i la i ème entrée de D , alors

$$Ax_i = \lambda_i x_i. \tag{6}$$

Le vecteur x_i est donc un vecteur propre de A , et λ_i est sa valeur propre associée. La décomposition en valeurs propres est un changement de base vers les coordonnées des vecteurs propres. Si $Av = b$ et la matrice A se décompose $A = XDX^{-1}$, on a

$$D(X^{-1}v) = X^{-1}b \tag{7}$$

Les vecteurs $X^{-1}v$ et $X^{-1}b$ sont les vecteurs v et b exprimés dans la base des vecteurs propres que sont les colonnes de X . Dans cette base, la matrice A s'exprime comme une matrice diagonale D , qui agit sur chaque vecteur par multiplications scalaires. (La

4 : Décomposition en valeurs singulières (SVD)

Soit A une matrice de taille $m \times n$

Définition Une **décomposition en valeurs singulières** (SVD – Singular Value Decomposition) est une factorisation $A = U\Sigma V^*$ où

- $U \in \mathbb{C}^{m \times m}$ est unitaire
- $V \in \mathbb{C}^{n \times n}$ est unitaire
- $\Sigma \in \mathbb{C}^{m \times n}$ est diagonale et les coefficients $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_p$, où $p = \min(m, n)$.

$$\begin{bmatrix} A \end{bmatrix} = \begin{bmatrix} \textcolor{red}{U} & \textcolor{green}{\Sigma} & V^* \end{bmatrix}$$

Décomposition complète


$$\begin{bmatrix} A \end{bmatrix} = \begin{bmatrix} \textcolor{red}{U} & \textcolor{green}{\Sigma} & V^* \end{bmatrix}$$

Décomposition réduite

4 : Décomposition en valeurs singulières (SVD)

Interpretation

A une matrice de taille $m \times n \rightarrow A = U\Sigma V^*$





n vecteurs singuliers d'entrée de A

n vecteurs singuliers de sortie de A

n valeur singulières de A

4 : Décomposition en valeurs singulières (SVD)



4 : Décomposition en valeurs singulières (SVD)

Exemple issu de <https://aaronschlegel.me/image-compression-singular-value-decomposition.html> :

```
r <- lion[,1]
g <- lion[,2]
b <- lion[,3]

lion.r.svd <- svd(r)
lion.g.svd <- svd(g)
lion.b.svd <- svd(b)

rgb.svds <- list(lion.r.svd, lion.g.svd, lion.b.svd)

for (j in seq.int(3, round(nrow(lion), -2), length.out = 8)) {
  a <- sapply(rgb.svds, function(i) {
    lion.compress <- i$u[,1:j] %*% diag(i$d[1:j]) %*% t(i$v[,1:j])
  }, simplify = 'array')
}
```



Image RGB 600x337

4 : Décomposition en valeurs singulières (SVD)



Rang 300

4 : Décomposition en valeurs singulières (SVD)




Rang 173

4 : Décomposition en valeurs singulières (SVD)



Rang 45

4 : Décomposition en valeurs singulières (SVD)



Rang 3

4 : Décomposition en valeurs singulières (SVD)

Théorème 3.1. *existence et unicité de la SVD. Toute matrice $A \in \mathbb{C}^{n \times n}$ possède une SVD. Les valeurs singulières $\{\sigma_i\}$ sont déterminées de façon unique. Si A est carrée ($m = n$) et les valeurs singulières σ_j sont distinctes, les vecteurs d'entrée et de sorties v_j et u_j sont déterminés de façon unique à un facteur complexe unité près.*

Théorème 3.2. *Les valeurs singulières d'une matrice A sont les racines carrées des valeurs propres non-nulles de A^*A et AA^**

Théorème 3.3. *Les colonnes de U sont les vecteurs propres orthogonaux de AA^* et les colonnes de V sont les vecteurs propres orthogonaux de A^*A à unité complexe près.*

5 : Matrices de covariances

Partie inspirée de :

- Cours de F. et M. Diener (U. Nice)
- Cours de L. Tournier (U. Paris 13)

Définition : Soient $x = (x_1, x_2, \dots, x_n)$ et $y = (y_1, y_2, \dots, y_n)$ deux échantillons de même taille n et de moyenne respective $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ et $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$.

On appelle *covariance* (estimée¹) de x avec y et on note $\text{cov}(x, y)$ le nombre

$$\text{cov}(x, y) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}).$$

On appelle *variance* (estimée) de x et on note $\text{Var}(x)$ le nombre

$$\text{Var}(x) = \text{cov}(x, x) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2,$$

et $\sqrt{\text{Var}(x)}$ s'appelle *l'écart-type* de l'échantillon x . On appelle *corrélation* de x avec y et on note $\text{cor}(x, y)$ le nombre

$$\rho = \text{cor}(x, y) = \frac{\text{cov}(x, y)}{\sqrt{\text{Var}(x)} \sqrt{\text{Var}(y)}}.$$

5 : Matrices de covariances

Soit X une variable aléatoire à valeurs dans \mathbb{R}^d . On note $X = {}^t(X_1 \ \dots \ X_d)$. Les variables aléatoires réelles X_1, \dots, X_d sont appelées les *composantes* de X et leurs lois sont les *lois marginales* de la loi de X . On définit classiquement son espérance (sa moyenne)

$$m_X = \mathbb{E}[X] = \begin{pmatrix} \mathbb{E}[X_1] \\ \vdots \\ \mathbb{E}[X_d] \end{pmatrix}$$

et aussi, si X_1, \dots, X_d sont de carré intégrable, sa variance

$$\begin{aligned} \Gamma_X &= \text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^t(X - \mathbb{E}[X])] \\ &= (\text{Cov}(X_i, X_j))_{1 \leq i, j \leq d} \\ &= \begin{pmatrix} \text{Var}(X_1) & \text{Cov}(X_1, X_2) & \cdots & \text{Cov}(X_1, X_d) \\ \text{Cov}(X_2, X_1) & \text{Var}(X_2) & \cdots & \text{Cov}(X_2, X_d) \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(X_d, X_1) & \text{Cov}(X_d, X_2) & \cdots & \text{Var}(X_d) \end{pmatrix}, \end{aligned}$$

En particulier, si X_1, \dots, X_d sont indépendantes deux à deux, alors Γ_X est une matrice diagonale ayant pour coefficients diagonaux $\text{Var}(X_1), \dots, \text{Var}(X_d)$.

Comme $\text{Cov}(X, Y) = \text{Cov}(Y, X)$ (ou comme ${}^t(A^t A) = A^t A$), la matrice Γ_X est symétrique. Elle est de plus positive : pour tout vecteur $u \in \mathbb{R}^d$,



$${}^t u \Gamma_X u = \sum_{i,j} u_i \text{Cov}(X_i, X_j) u_j = \sum_{i,j} \text{Cov}(u_i X_i, u_j X_j) = \text{Var}(u_1 X_1 + \cdots + u_d X_d) \geq 0.$$

5 : Matrices de covariances

$$\Gamma_X = \text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^t(X - \mathbb{E}[X])]$$

$$= (\text{Cov}(X_i, X_j))_{1 \leq i, j \leq d}$$

$$= \begin{pmatrix} \text{Var}(X_1) & \text{Cov}(X_1, X_2) & \cdots & \text{Cov}(X_1, X_d) \\ \text{Cov}(X_2, X_1) & \text{Var}(X_2) & \cdots & \text{Cov}(X_2, X_d) \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(X_d, X_1) & \text{Cov}(X_d, X_2) & \cdots & \text{Var}(X_d) \end{pmatrix},$$



5 : Matrices de covariances

Théorèmes importants liés aux matrices de covariances :

Théorème 1 – Théorème de Cochran. Soit $X \sim \mathcal{N}(m, \sigma^2 I_d)$, et $\mathbb{R}^d = E_1 \overset{\perp}{\oplus} \dots \overset{\perp}{\oplus} E_r$ une décomposition de \mathbb{R}^d en sous-espaces (affines) orthogonaux. Pour $k = 1, \dots, r$, on note d_k la dimension de E_k , et P_k la projection orthogonale sur E_k . Alors les variables aléatoires $Y_1 = P_1 X, \dots, Y_r = P_r X$ sont indépendantes, et

$$Y_k \sim \mathcal{N}(P_k m, \sigma^2 P_k) \quad \text{et} \quad \frac{1}{\sigma^2} \|Y_k - P_k m\|^2 \sim \chi_{d_k}^2.$$

Dans l'énoncé, χ_d^2 est la loi du χ^2 (khi-deux) à d degrés de liberté, c'est-à-dire par définition la loi de la variable aléatoire $Z_1^2 + \dots + Z_r^2$ où Z_1, \dots, Z_r sont i.i.d. de loi $\mathcal{N}(0, 1)$.

Théorème 2 – Théorème central limite multidimensionnel. Soit X_1, X_2, \dots une suite de vecteurs aléatoires à valeurs dans \mathbb{R}^d , i.i.d., de carré intégrable, de moyenne m et de variance Γ . Alors

$$\frac{1}{\sqrt{n}} (X_1 + X_2 + \dots + X_n - nm) \xrightarrow[n]{\text{(loi)}} \mathcal{N}(0, \Gamma).$$

5 : Matrices de covariances

Test de sphéricité de Bartlett : Teste l'indépendance globale des composantes d'un vecteur aléatoire

→ Echantillon de n réalisations de p v.a. réelles X_1, X_2, \dots, X_p : $X =$

$$\begin{pmatrix} x_1^1 & x_1^2 & \cdots & x_1^p \\ x_2^1 & x_2^2 & \cdots & x_2^p \\ \vdots & \vdots & \ddots & \vdots \\ x_n^1 & x_n^2 & \cdots & x_n^p \end{pmatrix}$$


→ Matrice de corrélation R (directement calculable à partir de $Var(X)$)

H_0 (hypothèse nulle) : les variables sont globalement indépendantes

H_1 : les variables sont globalement dépendantes

Le test évalue $t = - \left(n - 1 - \frac{2p + 5}{6} \right) \log(|\det R|)$ qui sous H_0 suit une loi du χ^2 à
 $k = \frac{p(p - 1)}{2}$ degrés de libertés

5 : Matrices de covariances



MERCI !!!